

B-MoE : Mixture of Experts à Routage par Blocs et Spécialisation Guidée des Experts

Technical Report — Confidentiel

Sébastien Viou

Juin 2026

Abstract

Nous proposons **B-MoE** (*Bloc-routed Mixture of Experts*), une architecture étendant les Mixture of Experts (MoE) selon trois axes complémentaires : (1) un **routage par blocs** opérant tous les Z couches, réduisant le nombre de décisions discrètes et stabilisant le gradient ; (2) un **mécanisme de scoring par attention inter-experts** à chaque point de routage, permettant une décision informée par la sémantique collective des experts actifs ; (3) une **initialisation guidée par domaine** (*pre-specialization*), inspirée de la modularité fonctionnelle corticale, accélérant la convergence et garantissant la diversité des représentations. Par rapport au travail le plus proche, RMoE [4], qui introduit un GRU inter-couches pour propager les décisions de routage, B-MoE se distingue sur trois points : le routage opère sur des blocs de Z couches et non couche-par-couche, le mécanisme de scoring repose sur une attention inter-experts sur les sorties agrégées du bloc plutôt que sur un état récurrent scalaire, et la spécialisation est initialisée *a priori* avant l'entraînement joint plutôt qu'émergente. Nous établissons les propriétés théoriques principales de ces trois mécanismes et discutons leur intégration dans un pipeline d'entraînement unifié.

1 Introduction

Les architectures Mixture of Experts [1] permettent d'augmenter massivement la capacité paramétrique d'un modèle sans augmentation proportionnelle du coût computationnel. Dans les formulations actuelles (Switch Transformer [2], Mixtral [3]), le routage est effectué indépendamment à chaque couche, sans mémoire des décisions antérieures.

Cette indépendance couche-par-couche présente trois limitations fondamentales :

1. Le router à la couche ℓ ignore quels experts ont été activés aux couches $\ell - 1, \dots, \ell - k$, perdant une information de contexte précieuse sur la trajectoire d'activation.
2. La multiplicité des décisions de routage introduit du bruit dans le gradient sur les réseaux profonds, fragilisant la convergence des routers.
3. Sans contrainte de spécialisation, les experts tendent vers la redondance (*expert collapse*), réduisant l'efficacité paramétrique effective du modèle.

RMoE [4] a récemment adressé la première limitation en introduisant un GRU pour propager l'état de routage couche-par-couche. B-MoE adopte une stratégie différente et complémentaire : au lieu de propager un état récurrent à chaque couche, nous groupons les couches en *blocs* de taille Z , effectuons le routage à la granularité du bloc via une attention inter-experts, et initialisons les experts par domaine avant l'entraînement joint.

2 Travaux connexes

Routage inter-couches. Le routage standard dans les MoE [1,2] est indépendant à chaque couche. RMoE [4] est le travail le plus directement connexe : il introduit un GRU léger entre les routers de couches consécutives, propageant l'information de routage couche par couche. Notre approche diffère en deux points : (i) le routage opère à la granularité du *bloc* (Z couches), réduisant le nombre de décisions de L à $B = L/Z$; (ii) le mécanisme de scoring repose sur une attention sur les sorties agrégées du bloc, pas sur un état GRU scalaire. Les deux approches sont orthogonales et potentiellement composables.

Spécialisation des experts. Branch-Train-Merge [5] entraîne des experts séparément sur des domaines distincts puis les fusionne — spécialisation explicite mais post-hoc, sans entraînement joint. UpIT [6] assigne des données spécialisées à chaque expert lors d’un upcycling depuis un dense, avec une loss de classification auxiliaire. Expert Divergence Learning [7] guide la spécialisation en décomposant le corpus d’entraînement par domaine. B-MoE se distingue en initialisant les experts *avant* l’entraînement joint (pré-spécialisation *a priori*), ce qui oriente le paysage de loss dès le début de l’optimisation plutôt qu’en contraignant le routage en cours d’entraînement.

Routage par profondeur et blocs. Mixture-of-Depths [8] alloue dynamiquement le compute par token selon la profondeur, mais ne fixe pas d’expert par bloc. Les Universal Transformers [9] réutilisent les mêmes poids sur plusieurs passes, ce qui est adjacent à notre notion de bloc mais sans routing différencié. À notre connaissance, aucun travail ne combine routage par blocs, scoring par attention inter-experts et pré-spécialisation *a priori* dans un cadre unifié.

3 Formalisation du cadre

3.1 Notations

Soit un transformer de profondeur L composé de N experts par position de routage. Notons :

- $\mathbf{h}_\ell^{(t)} \in \mathbb{R}^d$: le vecteur du *residual stream* au token t après la couche ℓ
- $E_i^{(\ell)} : \mathbb{R}^d \rightarrow \mathbb{R}^d$: la fonction de l’expert i à la couche ℓ
- $Z \in \mathbb{N}^*$: la taille d’un bloc (nombre de couches par décision de routage)
- $B = \lfloor L/Z \rfloor$: le nombre total de blocs
- $\sigma_b \in \{1, \dots, N\}$: l’indice de l’expert actif dans le bloc b

3.2 Structure en blocs

Définition 1 (Bloc B-MoE). *Le bloc $b \in \{1, \dots, B\}$ correspond aux couches $\ell \in \{(b-1)Z + 1, \dots, bZ\}$. Au sein d’un bloc, un unique expert σ_b est actif pour l’ensemble des Z couches. Le residual stream se propage selon :*

$$\mathbf{h}_\ell^{(t)} = \mathbf{h}_{\ell-1}^{(t)} + E_{\sigma_b}^{(\ell)}(\mathbf{h}_{\ell-1}^{(t)}), \quad \ell \in \text{bloc } b \quad (1)$$

La représentation agrégée à la sortie du bloc b est :

$$\mathbf{o}_b^{(t)} = \mathbf{h}_{bZ}^{(t)} \quad (2)$$

Remarque 1 (Comparaison avec RMoE). *Dans RMoE [4], le GRU propage un état caché $\mathbf{r}_\ell \in \mathbb{R}^{d_r}$ couche par couche : $\mathbf{r}_\ell = \text{GRU}(\mathbf{r}_{\ell-1}, \mathbf{h}_\ell)$. Le router à la couche ℓ conditionne sa décision sur $\mathbf{r}_{\ell-1}$. B-MoE supprime la granularité couche-par-couche : la décision de routage est prise une seule fois par bloc, sur la base de la sortie agrégée $\mathbf{o}_{b-1}$, réduisant le nombre de décisions discrètes de L à B .*

4 Routage inter-blocs par attention

4.1 Limitation du scoring scalaire

Dans les MoE standards, le router est un MLP $r : \mathbb{R}^d \rightarrow \mathbb{R}^N$ produisant un score scalaire par expert. Dans RMoE, le GRU enrichit ce score d’un état récurrent mais reste un vecteur de dimension d_r sans modéliser explicitement les relations entre experts. B-MoE introduit un scoring par attention sur les représentations de chaque expert.

4.2 Attention inter-experts

Soit $\mathbf{O}_b \in \mathbb{R}^{N \times d}$ la matrice des représentations agrégées de chaque expert au bloc b (voir section 4.3 pour les experts non actifs).

Définition 2 (Router par attention inter-experts). *Le score de routage pour le bloc $b + 1$ est calculé par :*

$$\mathbf{s}_{b+1} = \text{softmax}\left(\frac{\mathbf{Q}_b \mathbf{K}_b^\top}{\sqrt{d_k}}\right) \mathbf{V}_b \in \mathbb{R}^N \quad (3)$$

où $\mathbf{Q}_b = \mathbf{O}_b W_Q$, $\mathbf{K}_b = \mathbf{O}_b W_K$, $\mathbf{V}_b = \mathbf{O}_b W_V$, avec $W_Q, W_K \in \mathbb{R}^{d \times d_k}$ et $W_V \in \mathbb{R}^{d \times 1}$. L'expert sélectionné est :

$$\sigma_{b+1} = \arg \max_i s_{b+1,i} \quad (4)$$

4.3 Estimation des experts non actifs

Un expert $i \neq \sigma_b$ n'a pas produit de sortie au bloc b . Trois stratégies sont envisageables :

1. **Propagation du bloc précédent** : $\mathbf{o}_{b,i} \approx \mathbf{o}_{b-1,i}$ — approximation simple, coût nul.
2. **Forward partiel** : évaluer E_i sur un sous-échantillon de tokens pour estimer $\mathbf{o}_{b,i}$ — plus précis, surcoût linéaire en N .
3. **Projection apprise** : $\mathbf{o}_{b,i} = f_i(\mathbf{o}_{b-1,i}, \mathbf{h}_{bZ})$ avec f_i un MLP léger — compromis.

La stratégie (1) est suffisante pour un prototype et constitue l'hypothèse par défaut dans ce rapport. La stratégie (3) est recommandée pour un déploiement à grande échelle.

Proposition 1 (Différentiabilité du routage). *Le score $\mathbf{s}_{b+1}$ est différentiable par rapport aux paramètres W_Q, W_K, W_V et aux représentations $\mathbf{O}_b$. La sélection $\arg \max$ est rendue différentiable via Gumbel-Softmax [11] ou l'estimateur Straight-Through [10] lors de l'entraînement.*

Proof. $\mathbf{s}_{b+1}$ est une composition de fonctions différentiables en W_Q, W_K, W_V et $\mathbf{O}_b$. Seule l'opération $\arg \max$ est discontinue. En substituant par $\text{softmax}(\mathbf{s}_{b+1}/\tau)$ avec $\tau \rightarrow 0$ (Gumbel-Softmax) ou via le gradient straight-through sur la sélection binaire, le graphe de calcul reste différentiable de bout en bout. $\square$

5 Pré-spécialisation des experts

5.1 Motivation

Dans le cortex cérébral, la modularité fonctionnelle est partiellement innée : des zones dédiées au langage, à la perception visuelle ou au raisonnement spatial présentent des prédispositions structurelles avant toute expérience [12]. Cette initialisation guidée accélère la spécialisation post-natale sans l'imposer rigide.

Contrairement à Branch-Train-Merge [5] qui spécialise les experts séparément puis les fusionne (sans entraînement joint ultérieur), et à UpIT [6] qui opère en upcycling depuis un dense, B-MoE pré-spécialise les experts *avant* l'entraînement joint, orientant le paysage de loss dès l'initialisation.

5.2 Procédure

Définition 3 (Corpus de pré-spécialisation). *Soit $\mathcal{D} = \{\mathcal{D}_1, \dots, \mathcal{D}_N\}$ une partition de corpus par domaine. Chaque expert E_i est pré-entraîné sur $\mathcal{D}_i$ pendant T_{pre} étapes :*

$$\mathcal{L}_{\text{pre}}(E_i) = -\mathbb{E}_{x \sim \mathcal{D}_i} [\log p_{E_i}(x)] \quad (5)$$

Théorème 2 (Divergence garantie des experts). *Soient E_i et E_j pré-spécialisés sur des corpus $\mathcal{D}_i$ et $\mathcal{D}_j$ disjoints. Sous des hypothèses de régularité standard (loss localement μ -fortement convexe), les paramètres θ_i^* et θ_j^* issus de la minimisation de $\mathcal{L}_{\text{pre}}$ vérifient :*

$$\|\theta_i^* - \theta_j^*\|_2 \geq \delta(\mathcal{D}_i, \mathcal{D}_j) > 0 \quad (6)$$

où δ est une fonction croissante de $D_{\text{KL}}(p_{\mathcal{D}_i} \| p_{\mathcal{D}_j})$.

Esquisse. Par convergence du SGD, θ_i^* minimise localement $\mathcal{L}_{\text{pre}}(E_i)$. Si $D_{\text{KL}}(p_{\mathcal{D}_i} \| p_{\mathcal{D}_j}) > 0$, les gradients attendus $\mathbb{E}_{x \sim \mathcal{D}_i} [\nabla \mathcal{L}]$ et $\mathbb{E}_{x \sim \mathcal{D}_j} [\nabla \mathcal{L}]$ diffèrent, induisant des minimiseurs distincts. La borne inférieure découle de la μ -forte convexité locale et de l'écart entre gradients. $\square$

5.3 Entraînement joint

Après pré-spécialisation, l’entraînement joint maintient la diversité via deux termes de régularisation :

$$\mathcal{L}_{\text{div}} = -\lambda \sum_{i \neq j} D_{\text{KL}}(p_{\theta_i} \| p_{\theta_j}) \quad (7)$$

$$\mathcal{L}_{\text{bal}} = \alpha \sum_{b=1}^B \sum_{i=1}^N \left(f_{b,i} - \frac{1}{N} \right)^2 \quad (8)$$

où $f_{b,i}$ est la fraction de tokens routés vers l’expert i au bloc b . La loss totale est :

$$\mathcal{L} = \mathcal{L}_{\text{LM}} + \mathcal{L}_{\text{div}} + \mathcal{L}_{\text{bal}} \quad (9)$$

6 Propriétés théoriques

Proposition 3 (Réduction du vanishing gradient sur les routers). *Dans un MoE à routage couche-par-couche, le gradient de la loss par rapport aux paramètres du router à la couche ℓ décroît avec la profondeur. Dans B-MoE, le nombre de décisions de routage est réduit à $B = L/Z$, et le gradient intra-bloc se propage sans décision discrète intermédiaire via les connexions résiduelles :*

$$\left\| \frac{\partial \mathcal{L}}{\partial W_{\text{router}}^{(b)}} \right\|_{\text{B-MoE}} \geq \left\| \frac{\partial \mathcal{L}}{\partial W_{\text{router}}^{(\ell)}} \right\|_{\text{standard}} \cdot C^{Z-1} \quad (10)$$

pour une constante $C > 1$ liée à la norme spectrale des couches du bloc.

Proof. Dans le routage standard, le gradient doit traverser L opérations discrètes. Avec le routage par blocs, il en traverse $B = L/Z$. Le residual stream intra-bloc propage le gradient directement à travers Z couches continues, préservant sa norme via les skip connections. $\square$

Proposition 4 (Complexité computationnelle). *Le surcoût du router inter-experts par rapport à un MLP scalaire standard est $\mathcal{O}(N^2 d_k / Z)$ par couche, amorti sur Z couches. Pour $N \leq 16$, $d_k \ll d$ et $Z \geq 4$, ce surcoût est négligeable devant le coût des couches transformer.*

7 Comparaison avec l’état de l’art

Architecture	Routage inter-couches	Scoring	Spécialisation	Stabilité gradient
Switch Transformer [2]	×	Scalaire	×	Faible
Mixtral [3]	×	Scalaire (top-2)	×	Faible
RMoe [4]	GRU couche/couche	Scalaire	×	Moyenne
Branch-Train-Merge [5]	×	—	Post-hoc	N/A
UpIT [6]	×	Scalaire	Upcycling	Moyenne
B-MoE (ce travail)	Attention/bloc	Inter-experts	A priori	Élevée

8 Discussion et limitations

Valeur de Z . C’est le paramètre le plus sensible. Nous recommandons $Z \in [L/16, L/8]$ comme plage initiale, soit $Z \in [6, 12]$ pour $L = 96$.

Limitation principale : estimation de $\mathbf{O}_b$ pour les experts non actifs. La stratégie (1) (propagation du bloc précédent) introduit un biais : si la représentation d’un expert non actif a fortement divergé depuis le bloc précédent, le score de routage peut être mal calibré. Cette limitation est le point théorique le plus vulnérable de B-MoE et constitue une priorité pour la validation empirique.

Définition des domaines de pré-spécialisation. La partition $\{\mathcal{D}_i\}$ requiert une taxonomie préalable qui peut être sous-optimale pour des tâches hybrides. Une extension naturelle est d’apprendre la partition via clustering sur les embeddings du corpus.

Composabilité avec RMoe. B-MoE et RMoe sont orthogonaux : le mécanisme GRU de RMoe pourrait être appliqué à l’intérieur des blocs de B-MoE pour propager l’information intra-bloc, tandis que l’attention inter-experts opérerait au niveau inter-blocs. Cette composition est une direction de recherche future.

9 Conclusion

B-MoE propose une architecture MoE combinant trois contributions complémentaires : routage par blocs pour la stabilité du gradient, attention inter-experts pour un scoring sémantiquement informé, et pré-spécialisation guidée pour la diversité et la convergence. La différenciation principale par rapport à RMoE [4] réside dans la granularité du routage (bloc vs couche), le mécanisme de scoring (attention inter-experts vs GRU scalaire), et l’initialisation (a priori vs émergente). Les propriétés théoriques établies constituent une base formelle pour une validation empirique sur des modèles de taille intermédiaire (1B–7B paramètres), en particulier sur la question ouverte de l’estimation des experts non actifs.

References

- [1] N. Shazeer et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *ICLR*, 2017.
- [2] W. Fedus, B. Zoph, N. Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *JMLR*, 2022.
- [3] A. Q. Jiang et al. Mixtral of experts. *arXiv:2401.04088*, 2024.
- [4] Z. Qiu, Z. Huang, S. Cheng, Y. Zhou, Z. Wang, I. Titov, J. Fu. Layerwise recurrent router for mixture-of-experts. *ICLR*, 2025. *arXiv:2408.06793*.
- [5] M. Li et al. Branch-train-merge: Embarrassingly parallel training of expert language models. *arXiv:2208.03306*, 2022.
- [6] [Auteurs]. Upcycling instruction tuning from dense to mixture-of-experts. *ACL*, 2025.
- [7] [Auteurs]. Expert divergence learning for MoE-based language models. *arXiv:2603.00054*, 2026.
- [8] D. Raposo et al. Mixture-of-depths: Dynamically allocating compute in transformer-based language models. *arXiv:2404.02258*, 2024.
- [9] M. Dehghani et al. Universal transformers. *ICLR*, 2019.
- [10] Y. Bengio, N. Léonard, A. Courville. Estimating or propagating gradients through stochastic neurons. *arXiv:1308.3432*, 2013.
- [11] E. Jang, S. Gu, B. Poole. Categorical reparameterization with gumbel-softmax. *ICLR*, 2017.
- [12] S. Dehaene, L. Cohen. The unique role of the visual word form area in reading. *Trends in Cognitive Sciences*, 2005.